

Ứng dụng mạng Neural đa tầng (MLP) trong dự báo rủi ro tín dụng tại Home Credit

*Note: Sub-titles are not captured in Xplore and should not be used

1st Trần Thị Thúy Hiền
Faculty of Information Technology
HUTECH University
Ho Chi Minh City, Vietnam
tranthithuyhien2022@gmail.com

2nd Phạm Nguyễn Quốc Bình
Faculty of Information Technology
HUTECH University
Ho Chi Minh City, Vietnam
phambinh24012005@gmail.com

3rd Ngô Phi Phụng
Faculty of Information Technology
HUTECH University
Ho Chi Minh City, Vietnam
phiphungngo0901@gmail.com

Abstract—Nghiên cứu này tập trung vào đánh giá rủi ro tài chính – yếu tố sống còn trong quản trị tài chính doanh nghiệp. Tuy nhiên, các mô hình học máy truyền thống thường gặp nhiều khó khăn khi đối mặt với dữ liệu thực tế có độ mất cân bằng nghiêm trọng. Không giống các phương pháp truyền thống chỉ áp dụng trực tiếp các thuật toán học máy lên dữ liệu thô, nghiên cứu này đóng góp ba giá trị cốt lõi:

- Thứ nhất: Quá trình trích xuất đặc trưng dựa trên kiến thức nghiệp vụ tài chính được thực hiện để xây dựng các biến số có sức mạnh dự đoán cao, điển hình là chỉ số áp lực tín dụng (CREDIT_TERM) và các chỉ số tổng hợp điểm tín dụng bên ngoài (EXT_SOURCES_MEAN, EXT_SOURCES_PROD).
- Thứ hai: Kỹ thuật lấy mẫu kết hợp giữa SMOTE và Random Under-Sampling được áp dụng để cân bằng phân phối nhân, khắc phục hiện tượng thiên lệch mô hình.
- Thứ ba: Kiến trúc MLP được huấn luyện với các cơ chế kiểm soát quá khớp (overfitting) gồm Early Stopping và ReduceLROnPlateau, giúp mô hình tổng quát hóa tốt trên dữ liệu thực tế.

Kết quả thực nghiệm trên bộ dữ liệu quy mô lớn Home Credit cho thấy mô hình đề xuất đạt chỉ số ROC-AUC là 0.8791 và độ nhạy phát hiện nợ xấu (Recall) lên tới 0.800. Hiệu năng này thể hiện sự vượt trội hoàn toàn so với các mô hình học máy tập hợp (Ensemble Learning) phổ biến như Random Forest và LightGBM, qua đó khẳng định tính khả thi của MLP trong việc xây dựng các hệ thống cảnh báo rủi ro tín dụng có độ tin cậy cao.

I. GIỚI THIỆU

Trong bối cảnh hệ thống tài chính không ngừng mở rộng quy mô tín dụng tiêu dùng, việc đánh giá và kiểm soát rủi ro vỡ nợ (credit default risk) trở thành một trong những nhiệm vụ cốt lõi và cấp thiết nhất. Rủi ro này phát sinh khi khách hàng không có khả năng hoàn trả đúng hạn, không chỉ gây tổn thất vốn trực tiếp mà còn đe dọa tính thanh khoản của toàn hệ thống. Theo thống kê của Ngân hàng Thế giới, nợ xấu là nguyên nhân hàng đầu dẫn đến các cuộc khủng hoảng tài chính, đặt ra yêu cầu bức thiết về việc xây dựng các công cụ cảnh báo sớm chính xác và kịp thời.

Trong những thập kỷ qua, các mô hình chấm điểm tín dụng đã chuyển dịch mạnh mẽ từ phương pháp thống kê truyền

thống (như hồi quy Logistic, điểm Z-score) sang ứng dụng Học máy (Machine Learning). Các thuật toán học tập hợp (Ensemble Learning) như Random Forest hay LightGBM đã được ứng dụng rộng rãi nhờ tính hiệu quả cao. Tuy nhiên, khi đối mặt với dữ liệu tài chính thực tế quy mô lớn, các phương pháp này bộc lộ những hạn chế rõ rệt. Thứ nhất, chúng gặp khó khăn trong việc mô hình hóa các mối quan hệ phi tuyến tính phức tạp đa chiều. Thứ hai, và cũng là điểm yếu “chết người” nhất: sự mất cân bằng phân phối nhân (class imbalance) cực kỳ nghiêm trọng. Trong thực tế, số lượng hồ sơ nợ xấu luôn chiếm tỷ lệ rất nhỏ. Khi huấn luyện trên dữ liệu lệch, các mô hình thường thiên vị nhóm đa số (khách hàng trả nợ tốt), dẫn đến tỷ lệ bỏ lọt khách hàng rủi ro cao bị suy giảm nghiêm trọng. Hơn nữa, phần lớn các nghiên cứu hiện có thường tập trung vào việc tối ưu thuật toán đơn lẻ mà chưa chú trọng đúng mức đến giai đoạn tiền xử lý dữ liệu và tạo đặc trưng.

Xuất phát từ những khoảng trống nghiên cứu đó, bài báo này đề xuất một khung giải pháp học sâu (Deep Learning) toàn diện dựa trên mạng nơ-ron đa tầng (Multi-Layer Perceptron - MLP). Điểm khác biệt của nghiên cứu là sự kết hợp chặt chẽ giữa sức mạnh của mạng nơ-ron với quy trình tiền xử lý dữ liệu chuyên sâu. Toàn bộ giải pháp được kiểm nghiệm trên bộ dữ liệu quy mô lớn Home Credit Default Risk.

Cụ thể, bài báo mang đến những đóng góp chính sau đây:

- **Đề xuất phương pháp trích xuất đặc trưng (Feature Engineering) dựa trên tri thức nghiệp vụ:** Xây dựng các biến số mới phản ánh trực tiếp áp lực tài chính (tỷ lệ nợ/vay) và tổng hợp độ tin cậy từ các nguồn tín dụng bên ngoài, giúp bộc lộ rõ ranh giới rủi ro mà các đặc trưng thô không thể hiện được.
- **Xử lý triệt để bài toán mất cân bằng dữ liệu:** Ứng dụng chiến lược lấy mẫu lai (Hybrid Resampling) kết hợp thuật toán SMOTE để tăng cường nhân thiểu số và Random Under-Sampling để giảm bớt nhân đa số, tạo ra không gian dữ liệu cân bằng cho mô hình.
- **Tối ưu hóa kiến trúc mạng MLP:** Thiết kế mạng học sâu kết hợp cơ chế kiểm soát tốc độ học

động (ReduceLROnPlateau) và dừng sớm (Early Stopping) để tránh hiện tượng học vẹt (*overfitting*). Cung cấp bằng chứng thực nghiệm vững chắc cho thấy mô hình MLP đề xuất vượt trội hoàn toàn so với *Random Forest* và *LightGBM*, đặc biệt là nâng cao độ nhạy (*Recall*) trong việc phát hiện các hồ sơ vỡ nợ ẩn.

II. PHƯƠNG PHÁP THỰC NGHIỆM

A. Tổng quan quy trình

Nghiên cứu này đề xuất một quy trình xử lý và mô hình hóa toàn diện gồm bốn giai đoạn tuần tự: (1) Thu thập và tiền xử lý dữ liệu; (2) Phân tích khám phá và trích xuất đặc trưng; (3) Xử lý mất cân bằng phân phối; và (4) Xây dựng, tối ưu hóa kiến trúc mạng học sâu MLP. Mỗi giai đoạn được thiết kế có chủ đích nhằm giải quyết từng thách thức cụ thể của bài toán dự báo rủi ro tín dụng trong điều kiện dữ liệu thực tế.

B. Bộ dữ liệu

Nghiên cứu sử dụng bộ dữ liệu rủi ro tín dụng công khai *Home Credit Default Risk*, bao gồm hơn 300.000 hồ sơ vay vốn. Dữ liệu ban đầu cung cấp 121 đặc trưng thô, phản ánh đa chiều thông tin khách hàng từ nhân khẩu học, thông tin khoản vay, tài sản đến điểm tín dụng bên ngoài. Biến mục tiêu (*TARGET*) là biến nhị phân, trong đó nhãn 1 biểu thị khách hàng vỡ nợ và nhãn 0 là trả nợ đúng hạn. Khảo sát sơ bộ cho thấy tỷ lệ mất cân bằng nhãn xấp xỉ 1 : 11 (nhóm vỡ nợ chỉ chiếm khoảng 8%) — đây là thách thức trung tâm mà toàn bộ quy trình phương pháp hướng tới giải quyết.

C. Tiền xử lý dữ liệu

Giai đoạn tiền xử lý được thực hiện qua hệ thống *Pipeline* tự động với ba nhóm thao tác chính:

- **Xử lý ngoại lai:** Phát hiện lỗi hệ thống tại đặc trưng số ngày làm việc (*DAYS_EMPLOYED*) chứa giá trị 365243 (tương đương gần 1.000 năm). Các giá trị phi lý này được chuyển về dạng rỗng (NaN) nhằm bảo toàn số lượng mẫu thay vì xóa bỏ.
- **Nội suy:** Giá trị khuyết thiếu được điền bổ sung theo chiến lược: trung vị (*median*) cho biến liên tục và *mode* cho biến phân loại.
- **Mã hóa và Chuẩn hóa:** Các biến phân loại được mã hóa *One-Hot*. Sau đó, toàn bộ không gian đặc trưng liên tục được chuẩn hóa về cùng thang đo bằng thuật toán *StandardScaler*, đảm bảo tính ổn định trong quá trình tối ưu hóa *gradient*. Đồng thời, nghiên cứu loại bỏ các đặc trưng có độ tương quan dư thừa (*Pearson Correlation* > 0.9) để tránh đa cộng tuyến.

D. Phân tích khám phá dữ liệu và Trích xuất đặc trưng

1) **Phân tích tương quan:** Để định hướng cho quá trình trích xuất đặc trưng, nghiên cứu tiến hành phân tích ma trận tương quan giữa các đặc trưng tiềm năng và biến mục tiêu *TARGET*. Kết quả cho thấy nhóm đặc trưng điểm tín dụng bên ngoài (*EXT_SOURCES*) có mức tương quan âm mạnh nhất, trong đó trung bình điểm tín dụng

(*EXT_SOURCES_MEAN*) đạt hệ số tương quan -0.37 — cao nhất toàn tập dữ liệu. Quan sát này xác nhận giả thuyết rằng điểm tín dụng bên ngoài là tín hiệu phân biệt rủi ro mạnh nhất.




Figure 1. Ma trận tương quan các đặc trưng then chốt — *EXT_SOURCES_MEAN* có tương quan cao nhất với biến *TARGET*.

2) **Phân tích phân phối theo nhóm nhãn:** Đồ thị phân phối mật độ *kernel* (*KDE*) trực quan hóa khả năng phân biệt của đặc trưng *EXT_SOURCES_MEAN* giữa hai nhóm khách hàng. Phân phối của nhóm trả nợ tốt (nhãn 0) tập trung ở vùng giá trị chuẩn hóa dương, trong khi phân phối của nhóm vỡ nợ (nhãn 1) lệch hẳn về phía giá trị âm với đỉnh mật độ xấp xỉ -1.0 . Khoảng cách rõ ràng giữa hai đỉnh phân phối khẳng định tính hiệu quả của đặc trưng tổng hợp này.




Figure 2. Phân phối mật độ *KDE* của đặc trưng *EXT_SOURCES_MEAN* phân tách theo nhãn mục tiêu.

3) **Xây dựng đặc trưng mới:** Dựa trên kết quả phân tích EDA và tri thức nghiệp vụ tài chính, ba nhóm đặc trưng mới được kiến tạo:

- **Chỉ số áp lực tín dụng (*CREDIT_TERM*):** Phản ánh gánh nặng tài chính dài hạn:

$$CREDIT_TERM = \frac{AMT_CREDIT}{AMT_ANNUITY} \quad (1)$$

Giá trị này càng lớn đồng nghĩa với áp lực trả nợ kéo dài hơn và rủi ro vỡ nợ tích lũy cao hơn.

- **Chỉ số tín dụng tổng hợp (*EXT_SOURCES_MEAN* & *EXT_SOURCES_PROD*):** Ba nguồn điểm tín dụng rời

rạc được tổng hợp thành đại lượng trung bình số học và tích số, tạo ra một thước đo năng lực tài chính toàn diện hơn.

- **Các tỷ lệ tài chính:** Tỷ lệ thu nhập trên khoản trả góp ($\text{INCOME_TO_ANNUITY_RATIO}$) và tỷ lệ khoản vay trên giá trị hàng hóa ($\text{CREDIT_TO_GOODS_RATIO}$) được tính toán để đánh giá mức độ đòn bẩy tài chính.

E. Xử lý mất cân bằng dữ liệu

Nghiên cứu áp dụng chiến lược lấy mẫu lai (*Combined Resampling*) gồm kỹ thuật SMOTE (*Synthetic Minority Over-sampling Technique*) để tạo mẫu giả lập cho nhóm thiểu số và *Random Under-Sampling* để loại bỏ ngẫu nhiên mẫu từ nhóm đa số. Sự kết hợp này đưa tỷ lệ nhãn trong tập huấn luyện về mức cân bằng 50 – 50, buộc mô hình phải học ranh giới quyết định thực sự thay vì bị áp đảo bởi nhóm lành mạnh.

F. Kiến trúc mô hình MLP

Mô hình *Multilayer Perceptron* được thiết kế theo kiến trúc hình phễu với bốn lớp ẩn có số nơ-ron: $256 \rightarrow 128 \rightarrow 64 \rightarrow 32$.

- **Ổn định và Phi tuyến:** Sử dụng *Batch Normalization* sau mỗi lớp ẩn, tiếp theo là hàm kích hoạt *ReLU*. Lớp đầu ra sử dụng hàm *Sigmoid* để xuất xác suất trong khoảng $[0, 1]$.
- **Chống quá khớp:** Áp dụng *Dropout* (tỷ lệ 0.3) kết hợp chuẩn hóa L_2 (*L2 Regularization*).
- **Tối ưu hóa:** Sử dụng thuật toán *Adam*, hàm mất mát *Binary Cross-Entropy*, kích thước lô (*batch size*) 1024.
- **Cơ chế kiểm soát:** Tích hợp *Early Stopping* (độ trễ 10 epoch) và *ReduceLROnPlateau* (hệ số giảm 0.5) để tối ưu hóa quá trình hội tụ.

III. PHƯƠNG PHÁP THỰC NGHIỆM

A. Môi trường thực nghiệm

Toàn bộ thực nghiệm được thực hiện trên nền tảng *Python 3.10* với thư viện *TensorFlow/Keras* cho mô hình MLP, *scikit-learn* cho các mô hình nền tảng và các tiện ích tiền xử lý, cùng *imbalanced-learn* cho các kỹ thuật lấy mẫu. Quá trình huấn luyện được thực hiện trên môi trường *Google Colab* với GPU T4.

B. Phân chia dữ liệu

Bộ dữ liệu được phân chia theo tỷ lệ 80/20 cho tập huấn luyện và tập kiểm định, với kỹ thuật phân tầng (*stratified split*) để đảm bảo tỷ lệ nhãn được duy trì nhất quán giữa hai tập. Chiến lược lấy mẫu kết hợp SMOTE và *Under-Sampling* chỉ được áp dụng trên tập huấn luyện; tập kiểm định được giữ nguyên phân phối tự nhiên để phản ánh chính xác điều kiện triển khai thực tế.

C. Các mô hình so sánh

Để đánh giá hiệu năng tương đối của mô hình đề xuất, hai mô hình nền tảng (*baseline*) được huấn luyện trên cùng *pipeline* tiền xử lý và tập dữ liệu:

- **Random Forest:** Sử dụng 200 cây quyết định.
- **LightGBM:** Với các tham số mặc định được tinh chỉnh thông qua kiểm định chéo (*cross-validation*).

Việc giữ nguyên *pipeline* tiền xử lý và không gian đặc trưng đầu vào giúp đảm bảo tính công bằng trong so sánh, cô lập ảnh hưởng của riêng từng thuật toán phân loại.

D. Các chỉ số đánh giá

Do đặc thù bài toán mất cân bằng nhãn, nghiên cứu ưu tiên sử dụng các chỉ số đánh giá sau:

- **ROC-AUC:** Đo lường khả năng phân biệt tổng thể của mô hình trên toàn bộ ngưỡng quyết định, không phụ thuộc vào tỷ lệ nhãn.
- **Recall (Độ nhạy):** Đối với nhãn vỡ nợ, đây là chỉ số ưu tiên hàng đầu, phản ánh tỷ lệ khách hàng vỡ nợ thực sự được phát hiện đúng.

$$\text{Recall} = \frac{TP}{TP + FN} \quad (2)$$

Trong thực tế ngân hàng, chi phí bỏ sót một ca vỡ nợ (*False Negative*) luôn cao hơn nhiều so với chi phí cảnh báo nhầm (*False Positive*).

- **Precision và F1-Score:** Được sử dụng để đánh giá toàn diện sự đánh đổi giữa các loại lỗi.

$$F_1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (3)$$

IV. KẾT QUẢ THỰC NGHIỆM VÀ PHÂN TÍCH

A. Quá trình huấn luyện mô hình MLP

Hình 3 trình bày lịch sử huấn luyện mô hình MLP qua 100 *epoch*. Mô hình được xây dựng với kiến trúc ba tầng ẩn theo chuỗi $256 \rightarrow 128 \rightarrow 64$ nơ-ron, tổng cộng 104.705 tham số có thể học được, kết hợp *Batch Normalization* và *Dropout* (tỷ lệ lần lượt 0.4, 0.3, 0.2) sau mỗi tầng ẩn để kiểm soát hiện tượng quá khớp.

Về đường cong ROC-AUC, cả *Train AUC* và *Validation AUC* đều tăng mạnh trong 20 *epoch* đầu, từ khoảng 0.72 lên 0.85, phản ánh giai đoạn học nhanh khi mô hình nắm bắt được các tín hiệu phân biệt chính. Từ *epoch* 20 trở đi, tốc độ tăng chậm lại và *Validation AUC* hội tụ ổn định quanh ngưỡng 0.875–0.879. Khoảng cách giữa *Train AUC* (xấp xỉ 0.93) và *Validation AUC* (xấp xỉ 0.879) ở giai đoạn cuối phản ánh mức độ quá khớp vừa phải, được kiểm soát hiệu quả nhờ cơ chế *Dropout* kết hợp *Early Stopping*. Về *Binary Cross-Entropy Loss*, cả hai đường loss đều giảm đơn điệu xuyên suốt quá trình huấn luyện mà không xuất hiện hiện tượng phân kỳ, cho thấy quá trình tối ưu hóa diễn ra ổn định.




Figure 3. Lịch sử huấn luyện MLP — ROC-AUC và Binary Cross-Entropy Loss theo từng epoch.

B. Tầm quan trọng đặc trưng

Trong số 240 biến đầu vào bao gồm 106 biến gốc và 134 biến được tạo mới qua quá trình *Feature Engineering*, Hình 4 trình bày Top-20 đặc trưng có trọng số tuyệt đối trung bình cao nhất từ tầng đầu tiên của mạng MLP.

Ba đặc trưng dẫn đầu lần lượt là FLAG_OWN_REALTY (sở hữu bất động sản), FLAG_PHONE (có số điện thoại liên lạc) và CREDIT_TERM (chỉ số áp lực tín dụng), với *Mean |Weight|* dao động từ 0.110 đến 0.120. Đặc biệt, sự xuất hiện của CREDIT_TERM trong Top 3 là bằng chứng thực nghiệm thuyết phục cho hiệu quả của chiến lược trích xuất đặc trưng dựa trên tri thức nghiệp vụ: một biến được tạo thủ công từ tỷ lệ giữa khoản vay và thời hạn trả nợ lại vượt trội hơn phần lớn 106 biến gốc.




Figure 4. Top-20 đặc trưng quan trọng nhất theo trọng số tuyệt đối trung bình.

C. Kết quả phân loại — Ma trận nhầm lẫn

Hình 5 trình bày ma trận nhầm lẫn của mô hình MLP trên tập kiểm định gồm 33.923 quan sát. Sau khi áp dụng chiến lược *Combined Sampling* đưa tỷ lệ nợ xấu trong tập huấn luyện lên 33.33%, mô hình đạt kết quả phân loại cụ thể như sau:

- **Nhóm vỡ nợ:** Phát hiện đúng 8.744 trường hợp (*True Positive*) và bỏ lọt 2.564 trường hợp (*False Negative*), tương ứng với *Recall* = 0.80.
- **Nhóm lành mạnh:** Phân loại đúng 18.577 trường hợp (*True Negative*) và cảnh báo nhầm 4.038 trường hợp (*False Positive*), phản ánh *Precision* = 0.67 và *F1-Score* = 0.73.

Kết quả *Recall* 80% mang ý nghĩa thực tiễn: cứ 100 khách hàng vỡ nợ tiềm năng, mô hình phát hiện được 80 trường hợp. Sự bất cân xứng chi phí giữa hai loại lỗi trong nghiệp vụ tín dụng thực tế củng cố thêm tính hợp lý của chiến lược tối ưu hóa *Recall*.




Figure 5. Ma trận nhầm lẫn của MLP trên tập kiểm định — *Recall* nhóm vỡ nợ đạt 80%.

D. Đường cong ROC của mô hình đề xuất

Hình 6 trình bày đường cong ROC của mô hình MLP trên tập kiểm định, đạt *AUC* = 0.8791. Ngưỡng quyết định tối ưu theo tiêu chí *Youden* được xác định tại điểm (*FPR* = 0.179, *TPR* = 0.773) với giá trị ngưỡng xác suất 0.409. Trong triển khai thực tế, ngưỡng này có thể điều chỉnh linh hoạt tùy theo khẩu vị rủi ro của tổ chức tín dụng.




Figure 6. Đường cong ROC của mô hình MLP — *AUC* = 0.8791.

E. So sánh hiệu năng giữa các mô hình

Hình 7 trình bày so sánh đường cong ROC giữa ba mô hình. Bảng 1 tổng hợp đầy đủ các chỉ số hiệu năng.

Mô hình MLP đề xuất vượt trội so với cả hai mô hình nền tảng trên toàn bộ bốn chỉ số. Về *Recall*, MLP đạt 80%, vượt *LightGBM* (71.4%) và *Random Forest* (65.3%). Ưu thế của

Table I
TỔNG HỢP KẾT QUẢ SO SÁNH CÁC MÔ HÌNH

Mô hình	ROC-AUC	Recall	Precision	F1-Score
MLP (đề xuất)	0.8791	0.80	0.67	0.73
LightGBM	0.8120	0.714	0.665	0.633
Random Forest	0.7424	0.653	0.612	0.579

MLP bắt nguồn từ sự cộng hưởng của việc mã hóa tri thức nghiệp vụ tài chính qua *Feature Engineering*, chiến lược cân bằng dữ liệu 33.33% và năng lực học phi tuyến của kiến trúc phức tạp với 104.705 tham số.




Figure 7. So sánh đường cong ROC giữa MLP, *LightGBM* và *Random Forest*.

V. THẢO LUẬN VÀ ĐỊNH HƯỚNG NGHIÊN CỨU (DISCUSSION AND FUTURE WORK)

A. Thảo luận về kết quả thực nghiệm

1) *Sức mạnh cộng hưởng của Tri thức nghiệp vụ và Học sâu*: Một luận điểm thường thấy là các mô hình *Deep Learning* có khả năng tự động trích xuất đặc trưng mà không cần con người can thiệp. Tuy nhiên, kết quả thực nghiệm của bài báo này trên dữ liệu dạng bảng chứng minh điều ngược lại. Sự xuất hiện của các biến tự kiến tạo (như *CREDIT_TERM* và *EXT_SOURCES_MEAN*) trong nhóm các đặc trưng quan trọng nhất là bằng chứng thuyết phục cho giá trị của *Feature Engineering*. Việc “nén” thông tin từ các biến thô thành các chỉ số mang đậm ý nghĩa tài chính giúp định hướng cho mạng nơ-ron học các quan hệ phi tuyến bậc cao hiệu quả hơn nhiều so với việc để mô hình tự tìm kiếm. Điều này khẳng định: Tiền xử lý dữ liệu và Học sâu là hai mảnh ghép cộng hưởng, không thể thay thế lẫn nhau.

2) *Sự đánh đổi giữa Độ nhạy (Recall) và Độ suy diễn (Precision)*: Chiến lược SMOTE kết hợp *Under-Sampling* đã thành công trong việc nâng *Recall* của nhóm nợ xấu lên 80.0% — một bước nhảy vọt so với các mô hình không xử lý mất cân bằng (thường chỉ đạt *Recall* dưới 50%). Để đạt được

điều này, *Precision* phải dừng ở mức 67.0%. Dưới góc nhìn toán học, đây là một sự đánh đổi (*trade-off*). Tuy nhiên, dưới góc nhìn quản trị rủi ro ngân hàng, đây là một chiến lược tối ưu. Chi phí của một dự báo Âm tính giả (*False Negative* — cho người nợ xấu vay, dẫn đến mất trắng vốn) lớn hơn gấp nhiều lần so với dự báo Dương tính giả (*False Positive* — từ chối nhầm người tốt, chỉ mất phần tiền lãi). Việc đẩy *Recall* lên 80% chứng tỏ mô hình đã thiết lập thành công một lớp phòng vệ an toàn, đáp ứng chính xác khẩu vị rủi ro (*risk appetite*) của hệ thống tài chính.

3) *Ưu thế cấu trúc của mạng MLP*: Mặc dù khoảng cách về chỉ số AUC giữa MLP (0.8791) và thuật toán cây quyết định *LightGBM* (0.8120) có thể bị ảnh hưởng một phần bởi quá trình tinh chỉnh siêu tham số, nhưng MLP vẫn thể hiện ưu thế kiến trúc rõ rệt. Khi không gian dữ liệu mở rộng lên tới 240 đặc trưng với độ nhiễu cao, khả năng trích xuất các tương tác phức tạp (*complex interactions*) của các lớp ẩn mang lại lợi thế dự báo dài hạn và ổn định hơn khi áp dụng cho các danh mục tín dụng quy mô lớn.

B. Hạn chế của nghiên cứu

Nghiên cứu này tồn tại một số hạn chế cần được nhìn nhận khách quan:

- **Tính “hộp đen” và Rào cản pháp lý**: MLP vốn có tính giải thích (*explainability*) thấp hơn so với mô hình dạng cây. Việc không thể giải thích rõ ràng bằng các luật (*rules*) lý do tại sao một khách hàng bị từ chối khoản vay tạo ra rào cản lớn trong việc tuân thủ các quy định tài chính quốc tế (như GDPR) về quyền lợi khách hàng.
- **Giới hạn của thuật toán nội suy**: Chiến lược SMOTE tạo ra các mẫu tổng hợp dựa trên nội suy tuyến tính giữa các điểm dữ liệu. Trong một số trường hợp đặc thù, phương pháp này có thể không phản ánh chính xác phân phối phức tạp của nhóm vỡ nợ trong thực tế.
- **Hạn chế về tính tĩnh và phạm vi dữ liệu**: Nghiên cứu hiện mới tập trung vào bảng dữ liệu chính (*snapshot* tại thời điểm vay). Việc chưa khai thác các bảng dữ liệu phụ (như lịch sử tín dụng CIC, *previous_application*) và thiếu vắng các biến động chuỗi thời gian (*time-series*) đã bỏ lỡ nhiều tín hiệu dự báo quan trọng.

C. Định hướng nghiên cứu tương lai

Từ những kết quả và hạn chế trên, nghiên cứu đề xuất các hướng phát triển tiếp theo:

- **Giải quyết tính minh bạch bằng XAI (*Explainable AI*)**: Tích hợp các kỹ thuật như SHAP (*SHapley Additive exPlanations*) hoặc LIME vào sau lớp dự báo của MLP để xuất ra các báo cáo cá nhân hóa, giúp mô hình học sâu đáp ứng tiêu chuẩn kiểm toán khắt khe.
- **Mở rộng Kiến trúc dữ liệu và Mô hình nâng cao**: Khai thác toàn diện các bảng dữ liệu phụ thông qua *Graph-based learning*. Đồng thời, khảo sát các kiến trúc học sâu chuyên biệt cho dữ liệu bảng như *TabNet*, các

biến thể *Transformer*, hoặc xây dựng mô hình *Ensemble* lai giữa MLP và *LightGBM*.

- **Khai thác dữ liệu Chuỗi thời gian và Mạng lưới (GNN):** Kết hợp MLP với mạng nơ-ron hồi quy (RNN/LSTM) để xử lý dữ liệu lịch sử giao dịch và ứng dụng Mạng nơ-ron đồ thị (GNN) để phân tích mạng lưới quan hệ xã hội của khách hàng (bảo lãnh chéo, chung hộ khẩu).
- **Đánh giá tính tổng quát hóa:** Thử nghiệm khung giải pháp trên các bộ dữ liệu tín dụng từ nhiều thị trường tài chính và các bối cảnh kinh tế vĩ mô khác nhau để kiểm định tính bền vững của mô hình.

TÀI LIỆU THAM KHẢO

- [1] N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, "SMOTE: Synthetic minority over-sampling technique," *Journal of Artificial Intelligence Research*, vol. 16, pp. 321–357, 2002.
- [2] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. Cambridge, MA, USA: MIT Press, 2016.
- [3] G. Ke et al., "LightGBM: A highly efficient gradient boosting decision tree," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2017, pp. 3146–3154.
- [4] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [5] H. He and E. A. Garcia, "Learning from imbalanced data," *IEEE Transactions on Knowledge and Data Engineering*, vol. 21, no. 9, pp. 1263–1284, 2009.
- [6] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov, "Dropout: A simple way to prevent neural networks from overfitting," *The Journal of Machine Learning Research*, vol. 15, no. 1, pp. 1929–1958, 2014.
- [7] S. Ioffe and C. Szegedy, "Batch normalization: Accelerating deep network training by reducing internal covariate shift," in *Proceedings of the 32nd International Conference on Machine Learning (ICML)*, 2015, pp. 448–456.
- [8] D. P. Kingma and J. Ba, "Adam: A method for stochastic optimization," in *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*, 2015.
- [9] B. Baesens et al., "Benchmarking state-of-the-art classification algorithms for credit scoring," *Journal of the Operational Research Society*, vol. 54, no. 6, pp. 627–635, 2003.
- [10] L. C. Thomas, "A survey of credit and behavioural scoring: forecasting financial risk of lending to consumers," *International Journal of Forecasting*, vol. 16, no. 2, pp. 149–172, 2000.
- [11] A. Zheng and A. Casari, *Feature Engineering for Machine Learning: Principles and Techniques for Data Scientists*. Sebastopol, CA, USA: O'Reilly Media, 2018.
- [12] J. Blanco, G. Pino-Mejías, J. Lara, and S. Rayo, "Credit scoring models for the microfinance industry using neural networks: Evidence from Peru," *Expert Systems with Applications*, vol. 40, no. 1, pp. 356–364, 2013.
- [13] S. M. Lundberg and S.-I. Lee, "A unified approach to interpreting model predictions," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2017, pp. 4765–4774.
- [14] K. Li, X. Tian, and F. Zhu, "Credit risk assessment of micro and small enterprises based on integrated machine learning," *IEEE Access*, vol. 8, pp. 118485–118495, 2020.
- [15] J. Brownlee, *Imbalanced Classification with Python: Better Metrics, Balance Skewed Classes, Cost-Sensitive Learning*. Machine Learning Mastery, 2020.